

DSpark Draft 训练评测报告

Oct 9, 2026 · @人工智能-张伟峰

结论摘要

第五轮训练后的 draft(step_52)相对线上 released draft,接受长度从 2.5075 提升到 **3.0306(+20.9%)**,这是五轮里第一次越过 3.0。

推荐上线配置为 **第五轮 step_52,服务工作点并发 5**。在该工作点上:

- 端到端时延中位数 5,508 ms → **3,691 ms(-33.0%)**
- 每 token 时延 p99 11.88 ms → **6.82 ms(-42.6%)**
- 单请求吞吐 130.5 → **188.8 tok/s(+44.7%)**
- 投机解码的总加速从 1.41x 提升到 **1.99x**

接受长度在并发 1 / 5 / 10 三档读数为 3.0241 / 3.0365 / 3.0306,极差 0.4%,确认它是模型属性而非负载假象。

评测口径

所有轮次用同一套口径,除 draft 权重外没有任何参数差异,所以表中数字可直接横比。

项	值
样本	463 条(从 seed42 随机抽的 500 条中取可编码的),跳过 37 条 tool 轮
prompt 长度	中位数 14,003 token
生成上限	max_new_tokens = 1024
采样	temperature = 0,top_p = 1.0(与训练时 rollout 参数对齐)
并发	1 / 5 / 10 三档
服务	TP=4,DSPARK 投机解码,num_draft_tokens=6,cuda graph 和 radix cache 均开

对照组两个:**baseline(released)** 是 target 自带的 DSpark draft 头;**不开投机** 是关掉投机解码、其余参数逐字相同的对照。

完整结果

时延单位均为毫秒,吞吐为单请求 token/s。加粗为本轮推荐的上线候选。

并发 1

run	accept	TPOT p50	p90	p99	E2E p50	tok/s
不开投机	—	6.84	6.91	7.61	4,713	144.9
baseline	2.5100	3.60	3.87	4.89	2,570	275.4
第三轮 step_52	2.8723	3.15	3.47	4.37	2,181	315.8
第四轮 step_52	2.9093	3.10	3.43	4.57	2,172	319.5
第五轮 step_26	2.8887	3.12	3.48	4.25	2,177	318.2
第五轮 step_52	3.0241	2.98	3.29	4.25	2,097	332.9

并发 5

run	accept	TPOT p50	p90	p99	E2E p50	TTFT p50	tok/s
不开投机	—	10.57	11.98	13.12	7,672	377	93.9
baseline	2.5068	7.52	9.07	11.88	5,508	352	130.5
第三轮 step_52	2.8694	5.54	6.26	7.12	3,800	142	179.5
第四轮 step_52	2.9096	5.46	6.10	7.11	3,738	139	182.8
第五轮 step_26	2.8872	5.49	6.12	6.83	3,717	141	181.8
第五轮 step_52	3.0365	5.32	5.94	6.82	3,691	142	188.8

并发 10

run	accept	TPOT p50	p90	p99	E2E p50	tok/s
不开投机	—	15.30	17.70	20.36	10,909	64.5
baseline	2.5075	11.92	16.17	19.51	8,508	80.6
第三轮 step_52	2.8756	10.76	13.06	15.14	7,684	92.4
第四轮 step_52	2.9023	10.85	13.13	14.91	7,766	91.8
第五轮 step_26	2.8848	10.62	13.12	14.76	7,628	93.4
第五轮 step_52	3.0306	10.83	13.22	14.43	7,707	92.5

收益汇总

第五轮 step_52 相对 baseline:

并发	accept	TPOT p50	TPOT p99	E2E p50	吞吐	投机总加速
1	+20.48%	-17.2%	-13.1%	-18.4%	+20.9%	2.30x(baseline 1.90x)
5	+21.13%	-29.3%	-42.6%	-33.0%	+44.7%	1.99x (baseline 1.41x)
10	+20.86%	-9.1%	-26.0%	-9.4%	+14.9%	1.41x(baseline 1.28x)

接受长度的改善三档一致(约 +21%),但**时延收益高度依赖工作点**。并发 1 时服务没有排队,收益纯粹来自接受长度;并发 10 时排队主导,收益被稀释;并发 5 处在“接近饱和但尚未排队化”的位置,收益最大。

TTFT 的二阶效应

首 token 时延本应与 draft 无关——prefill 阶段投机解码不参与。并发 1 下实测确实无关(139 vs 137 ms,差 1.4%),这验证了口径没问题。

但并发 5 时 baseline 的 TTFT p50 是 352 ms,第五轮只有 142 ms(**-59.8%**),p90 相差 **80%**。机理是:接受长度低意味着同样的输出要多跑 44% 次 verify,GPU 被 decode 占用更久,新请求的 prefill 排不进去。

draft 质量差不只是吐字慢,它会把整个服务的响应性拖下去——而这恰恰发生在线上的真实负载区间。

公平性校验

两侧输出长度基本持平(差 ±3%),E2E 的比较没有被“谁吐得多”污染。单次 verify 的成本常数也对得上:baseline 是 $11.92 \times 2.5075 = 29.89$ ms,第五轮是 $10.83 \times 3.0306 = 32.82$ ms,同一量级。

历轮进展

轮次	步数	accept	vs baseline
baseline	—	2.5075	—
第二轮	18	2.5699	+2.49%
第三轮	52	2.8756	+14.68%
第四轮	52	2.9023	+15.74%
第五轮	52	3.0306	+20.86%

